

# Rešavanje problema optimalnog planiranja kretanja u grafu primenom genetskog algoritma

Seminarski rad u okviru kursa Računarska inteligencija Matematički fakultet

Petrović Ana, Spasojević Đorđe

pana.petrovic@gmail.com, djordje.spasojevic1996@gmail.com

3. septembar 2019

## Sažetak

U radu će biti predstavljen genetski algoritam prilagođen problemu optimalnog planiranja kretanja u grafu. ...


# Sadržaj

<b>1</b>	<b>Uvod</b>	<b>3</b>
<b>2</b>	<b>Opis algoritma</b>	<b>4</b>
2.1	Reprezentacija jedinke . . . . .	4
2.2	Funkcija prilagođenosti . . . . .	5
2.3	Selekcija . . . . .	6
2.4	Kreiranje nove generacije . . . . .	6
2.4.1	Ukrštanje . . . . .	7
2.4.2	Mutacija . . . . .	8
2.5	Prikaz algoritma . . . . .	9
<b>3</b>	<b>Rezultati</b>	<b>10</b>
<b>4</b>	<b>Zaključak</b>	<b>10</b>
	<b>Literatura</b>	<b>11</b>

# 1 Uvod

Planiranje kretanja (eng. *Motion Planning*) predstavlja jedan od opštih problema u oblasti robotike, čija postavka podrazumeva postojanje robota kojeg treba dovesti od početne tačke do cilja, uz izbegavanje postojećih prepreka [4]. U literaturi je prethodno ponuđeno više rešenja za ovaj problem primenom genetskog algoritma [1, 2, 5]. Iako nijedan od ovih pristupa nije sasvim primenjiv na konceptualizaciju našeg problema, svakako su nam ovi radovi pomogli da bolje razumemo sam problem i kako genetski da ga optimizujemo.

U ovom radu, dati problem je specifikovan tako da je potrebno naći sekvencu validnih poteza u povezanom, neusmerenom grafu. Radi pojednostavljivanja pronalaženja rešenja, odabrano je da se u primerima koriste samo aciklični grafovi. Graf se sastoji od unapred određenog broja čvorova, od koji svaki može u jednom trenutku da sadrži ili robota, ili prepreku, ili može biti slobodan. Jedan potez podrazumeva premeštanje robota ili prepreke u susedni slobodni čvor. Cilj je pronaći rešenje koje u najmanjem broju poteza dovodi robota od početnog čvora, označenog kao S, do ciljnog čvora, označenog kao T [3]. Na slici 1 je prikazan jednostavan primer postavke jednog ovakvog problema. U svim grafovima koje ćemo koristiti kao primere, čvor je crvene boje ako je na njemu trenutno prepreka, robot se nalazi na plavom čvoru, a ciljni čvor je obojen zelenom bojom dok je slobodan, a svetlo plavom ako je zauzet.



Slika 1: Primer postavke problema planiranja kretanja u grafu

## 2 Opis algoritma

U radu je dat predlog rešenja korišćenjem genetskog algoritma. Prvi, i jedan od najvažnijih koraka u genetskom algoritmu jeste određivanje načina na koji će jedinka (hromozom) biti predstavljena. Od reprezentacije hromozoma značajno zavisi ponašanje algoritma. Nakon toga, najčešće nasumično, generiše se početna populacija koja se sastoji od određenog broja jedinki. U narednom koraku, računa se kvalitet svake jedinke, tj. funkcija prilagođenosti, a na osnovu nje se vrši selekcija najprilagođenijih jedinki iz populacije. Potom se nad selektovanim jedinkama primene genetski operatori ukrštanja i mutacije, kojima se formiraju nove generacije, sve dok se ne dostigne neki kriterijum zaustavljanja i pronađe najbolje rešenje u datom trenutku.

### 2.1 Reprezentacija jedinke

Pri generisanju početne populacije, razmatrani su različiti načini predstavljanja rešenja. U većini prethodnih radova autori predlažu hromozom u obliku koordinata pozicija robota, ili putanje od početnog do krajnjeg čvora. Takva reprezentacija se nije dobro pokazala u našem slučaju, s obzirom na to da se prepreke mogu kretati na isti način kao i robot, kao i da postoji samo jedan put od čvora S do čvora T, jer je u pitanju aciklički graf.

Početnu populaciju u našem algoritmu čine jedinke koje predstavljaju neku nasumičnu putanju, odnosno niz različitih validnih poteza, koji počinju od početnog stanja grafa. Preciznije, jedinka se sastoji od pokreta robota ili prepreka, koji su predstavljeni preko izvornog čvora, ciljnog čvora, težine puta između ta dva čvora i liste koja predstavlja celu putanju. Na primer, potez od čvora A do čvora B je u obliku četvorke ('A', 'B', 1, ['A', 'B']). U slučaju pomeranja prepreka, dozvoljeni su potezi težine i veće od 1, jer je prethodno dokazano da kada je potrebno da se prepreka premesti u neki slobodan čvor (koji joj nije susedan), broj poteza je isti kao i dužina puta između ta dva čvora. Ono što je bitno u tom slučaju je da je na kraju tih poteza stanje grafa takvo da je slobodan polazni čvor, a ciljni zauzet preprekom [3].

Svaka od putanja u populaciji kreće od početnog stanja i zatim se za svaki naredni potez robota ili prepreke najpre razmatra da li je potez validan iz trenutnog stanja grafa, tj. trenutne pozicije prepreka i robota. Generiše se lista svih mogućih poteza iz trenutnog stanja i nasumično bira jedan iz liste. Zatim se izvrši taj potez i dobija se novo stanje grafa. Ako je novo stanje takvo da se robot nalazi u ciljnom čvoru, ne traže se naredni mogući potezi, jer je pronađeno rešenje. Ako je to stanje već ranije bilo razmatrano za tu jedinku, takav potez ne dodajemo u nju, jer ne želimo da se stanja ponavljaju. Može se desiti da se ovakvim nasumičnim dodavanjem istroše sva moguća stanja grafa i da više ne može da se doda nijedan potez. Iz tog razloga, dužina hromozoma neće biti fiksna, jer postoje slučajevi kada više neće biti validnih poteza iz nekog stanja. Maksimalna dužina jednog hromozoma *ChromosomeLength* određena je tako da bude proizvod dužine putanje od početnog čvora do ciljnog čvora, u oznaci P, i broja prepreka O koje se nalaze na toj putanji.

$$ChromosomeLength = P * O$$

## 2.2 Funkcija prilagođenosti

Svakoj jedinki dodeljuje se skor, čija visina ukazuje na prilagođenost jedinke. Skor se računa na osnovu poteza koji čine tu jedinku, i stanja grafa nakon tih izvršenih poteza, odnosno mesta na kojima se nalaze prepreke i robot nakon što su potezi izvršeni. Najpre se proverava da li je trenutno stanje robota jednako ciljnom čvoru T. Ukoliko se robot nalazi na cilju, skor se dodaje neki određen visok broj. Zatim se proverava da li je robot lociran na glavnoj putanji između početnog i ciljnog čvora, za šta se takođe dodaje određena vrednost na postojeći skor. Uz to, ukoliko se na tom putu nalazi neka prepreka, za svaku od njih se skor umanjuje za određenu vrednost. Ukoliko se nijedna prepreka ne nalazi na glavnom putu, a uz to je i ciljni čvor T slobodan, skor se povećava za određenu vrednost. Povrh toga, proverava se i da li jedinka sadrži pomenute nevalidne vrednosti koje se javljaju kada su ispunjena sva moguća stanja, i od skora se oduzima određena vrednost. Na kraju, od skora se oduzima i težina cele putanje jedinke pomnožena nekim faktorom. U nastavku je dat kod funkcije koja računa taj skor.

```
1000 def fitness_fun(chromosome, o, r, graph, t, path):
1002     weight = 0
1004     obstacles = o[:]
1006
1008     if r == t:
1010         score += SOLVED_AWARD
1012
1014     for node in path:
1016         if r == node:
1018             score += ROBOT_ON_PATH_AWARD
1020
1022     count_obs = 0
1024     for obstacle in obstacles:
1026         if obstacle in path:
1028             count_obs += 1
1030             score = score - OBSTACLE_PENALTY
1032
1034     if ssolver.is_hole(o, r, t) and count_obs == 0:
1036         score += CLOSE_AWARD
1038
1040     for move in chromosome:
1042         if move == ('0', '0', 0, []):
1044             score -= NO_MORE_STATES_PENALTY
1046             break
1048
1050     for i in range(len(chromosome)):
1052         weight += chromosome[i][2]
1054     score = - weight * WEIGHT_PENALTY
1056
1058     return score
```

Listing 1: Fitnes funkcija

## 2.3 Selekcija

Pri selekciji, vrši se izbor jedinki iz trenutne populacije za reprodukciju. U našem radu korišćena je turnirska selekcija. Turnirska selekcija podrazumeva da jedinke učestvuju u turnirima, a u svakom od njih, najbolje prilagođena jedinka se proglašava pobednikom. Veličina turnira zadata je parametrom `tournament_size`. U listu selektovanih jedinki se dodaju pobednici turnira sve dok veličina liste ne dostigne parametar `reproduction_size`.

```
1000 def tournament_selection(population, tournament_size):
1001     winner = None
1002     tournament = random.sample(population, tournament_size)
1003
1004     winner = max(tournament, key = lambda item: item[0])
1005
1006     return winner
1007
1008 def selection(population, reproduction_size, tournament_size):
1009     selected = []
1010
1011     while len(selected) < reproduction_size:
1012         selected.append(tournament_selection(population,
1013                                             tournament_size))
1014
1015     return selected
```

Listing 2: Turnirska selekcija

## 2.4 Kreiranje nove generacije

Pri kreiranju nove generacije, korišćena je strategija elitizma. Njome se obezbeđuje da se kvalitet rešenja ne smanjuje iz generacije u generaciju, tako što se uvek u narednu generaciju direktno prenosi određeni broj najbolje prilagođenih jedinki. U našem algoritmu, broj elitnih jedinki je velik (na primer, polovina veličine populacije) jer se pri generisanju populacije stvaraju veoma nasumične jedinke, s obzirom da se pri svakom potezu u potpunosti menja stanje grafa, odnosno menja se svaki mogući legitimni potez. Na ostale jedinke u populaciji koje ne prelaze direktno u narednu generaciju, primenjuje se operator ukrštanja, tako što se od prethodno selektovanih jedinki odabiraju dve nasumično, i one postaju roditelji. U ukrštanje će ulaziti samo jedinke koje su veće od neke minimalne dužine.

```
1000 def create_new_generation(population, selected, population_size,
1001                           elite_size, o, r, graph, t, path):
1002     new_generation = sorted(population, key = lambda item : item[0],
1003                             reverse = True)[:elite_size]
1004
1005     while len(new_generation) < population_size:
1006
1007         valid_parents = False
1008         while(valid_parents == False):
```

```

1010         parent1, parent2 = random.sample(selected, 2)
1012         if len(parent1[1]) > MIN_PARENT_LEN and
1014             len(parent2[1]) > MIN_PARENT_LEN:
1016             child = crossover(parent1, parent2, o, r, graph,
1018                             t, population_size, path)
1020             valid_parents = True
1022             if random.randrange(0, 100) < MUTATION_RATE:
1024                 mutated_child = mutation(child, o, r, graph,
1026                                         population_size, path, t)
1028                 new_generation.append(mutated_child)
1030             else:
1032                 new_generation.append(child)
1034     return new_generation

```

Listing 3: Generisanje nove generacije

### 2.4.1 Ukrštanje

Kako postoji velik broj elitnih jedinki, ukrštanje se vrši nad manjim brojem jedinki iz populacije. U našem algoritmu korišćeno je jednopoziciono ukrštanje, tako što je roditelj čija je putanja kraća presečen na nasumično odabranoj poziciji  $i$ . Deo poteza do  $i$  iz prvog roditelja mora da se izvrši da se dobije novo stanje grafa. Nakon toga, polazi se od  $i$ -te pozicije u drugom roditelju i za svaki pojedinačan potez proverava da li je moguć iz prethodno dobijenog stanja. Ovde nastaje problem, jer svaki put mora da se izvrši i doda novi potez na trenutno stanje, čime se dobija potpuno novo stanje. U velikom broju slučajeva potezi iz drugog roditelja neće biti mogući u datom stanju. Tada se dete dopunjava dokle god može. Tako dete koje nastaje često bude lošijeg kvaliteta od samog roditelja. Upravo iz tog razloga i koristimo elitizam sa tako velikim procentom. Ukrštanje mnogo komplikuje situaciju, jer za svaki novi potez iz drugog roditelja mora da se proverava da li je moguć u odnosu na *sve* prethodne, i samo ako jeste, može da se doda jedan potez, a već za sledeći možda opet neće biti moguće. Parametri funkcije ukrštanja su prvi roditelj, drugi roditelj, stanje prepreka, stanje robota, graf, ciljni čvor, veličina populacije i putanja od prvog do poslednjeg čvora.

```

1000 def crossover(parent1, parent2, o, r, graph,
1002              t, population_size, path):
1004     (score1, moves1) = parent1
1006     (score2, moves2) = parent2
1008
1010     obstacles = copy.deepcopy(o)
1012     robot = r
1014
1016     if len(moves1) <= len(moves2):
1018         i = random.randrange(1, len(moves1)-1)
1020         new_moves = moves1[:i]

```

```

1012     else:
1013         i = random.randrange(1, len(moves2)-1)
1014         new_moves = moves2[:i]
1015
1016     new_o, new_r = ssolver.make_moves(obstacles, robot,
1017                                       graph, new_moves)
1018
1019     if len(moves1) <= len(moves2):
1020         for j in range(i, len(moves2)):
1021             if moves2[j] in ssolver.possible_moves(new_o, new_r,
1022                                                    graph) and
1023                 different_moves(moves2[j],
1024                                new_moves[-1]):
1025                 new_moves.append(moves2[j])
1026                 new_o, new_r = ssolver.make_move(new_o, new_r, graph
1027 ,
1028                                                    moves2[j][0],
1029                                                    moves2[j][1])
1030
1031                 if new_r == t:
1032                     break
1033     else:
1034         for j in range(0, len(moves1)):
1035             if moves1[j] in ssolver.possible_moves(new_o, new_r,
1036                                                    graph) and
1037                 different_moves(moves1[j],
1038                                new_moves[-1]):
1039                 new_moves.append(moves1[j])
1040                 new_o, new_r = ssolver.make_move(new_o, new_r, graph
1041                                                    moves1[j][0],
1042                                                    moves1[j][1])
1043
1044                 if new_r == t:
1045                     break
1046
1047     child = fit_chromosome(new_moves, obstacles, robot,
1048                           graph, population_size, path, t)
1049     return child

```

Listing 4: Ukrštanje

### 2.4.2 Mutacija

Mutacija podrazumeva malu promenu genoma koja se dešava sa jako malom verovatnoćom, a koja omogućava različitost u narednoj generaciji i izbegavanje zaglavljivanja u lokalni optimum. U našem slučaju, mutacija će biti jednostavno dodavanje samo jednog poteza iz liste svih mogućih u trenutnom stanju, nakon izvršenih poteza do tog trenutka. Putanje su se nekad skraćivale u ukrštanju, pa će ih dodavanje jednog poteza možda unaprediti tako što će nastaviti kretanje, i možda u sledećem ukrštanju dozvoliti da se put produži.

```

1000 def mutation(chromosome, o, r, graph, population_size, path, t):
1001
1002     moves = chromosome[1]

```



```

1004 obstacles = copy.deepcopy(o)
1005 robot = r
1006 new_o, new_r = ssolver.make_moves(obstacles, robot,
                                     graph, moves)
1007
1008 pm = ssolver.possible_moves(new_o, new_r, graph)
1009
1010 for p in pm:
1011     if different_moves(p, moves[-1]):
1012         moves.append(p)
1013         break
1014
1015 new_o, new_r = ssolver.make_moves(copy.deepcopy(o), r,
                                     graph, moves)
1016
1017 mutated = fit_chromosome(moves, copy.deepcopy(o), r, graph,
                           population_size, path, t)
1018
1019 return mutated

```

Listing 5: Mutacija

## 2.5 Prikaz algoritma

U nastavku je dat kod funkcije koja radi optimizaciju, odnosno objedinjuje sve prethodno opisane korake i izvršava ih sve dok nije postignut kriterijum zaustavljanja, koji je odabran da bude neki maksimalan broj iteracija. Ako se nađe na dovoljno dobro rešenje, ono koje ima dovoljno visok skor iz pomenute fitnes funkcije pre nego što se generišu sve generacije, izlazi se iz petlje i vraća se to dovoljno dobro rešenje. Parametri funkcije su stanje prepreka o, stanje robota r, graf graph, ciljni čvor t, i putanja od početnog do ciljnog čvora path.

```

1000 def solve_genetic(o, r, graph, t, path):
1001
1002     chromosome_size = len(path) * OBSTACLES_IN_PATH
1003
1004     initial_population = create_initial_population(o, r, graph, t,
1005                                                    chromosome_size,
1006                                                    POPULATION_SIZE)
1007
1008     scored_population = []
1009     for i in range(POPULATION_SIZE):
1010         chromosome = initial_population[i]
1011         scored_population.append(fit_chromosome(chromosome, o,
1012                                                  r, graph,
1013                                                  population_size,
1014                                                  path, t))
1015
1016     current_pop = copy.deepcopy(scored_population)
1017
1018     for i in range(MAX_ITERATIONS):

```

```

1020     selected = selection(current_pop, REPRODUCTION_SIZE,
1021                          TOURNAMENT_SIZE)
1022     current_pop = create_new_generation(current_pop, selected,
1023                                       population_size, e
1024                                       lite_size, o, r,
1025                                       graph, t, path)
1026
1027     best = max(current_pop, key = lambda item:item[0])
1028     if best >= GOOD_ENOUGH:
1029         break
1030
1031     return best[1]

```

Listing 6: Genetski algoritam

### 3 Rezultati

### 4 Zaključak

## Literatura

- [1] Ismail AL-Taharwa, Alaa Sheta, and Mohammed Al-Weshah. A mobile robot path planning using genetic algorithm in static environment. 2008.
- [2] Sarah Alnasser and Hachemi Bennaceur. An efficient genetic algorithm for the global robot path planning problem. *Digital Information and Communication Technology and its Applications (DICTAP) 2016 Sixth International Conference*, 2016.
- [3] Christos H. Papadimitriou, Prabhakar Raghavan, Madhu Sudan, and Hisao Tamaki. Motion planning on a graph. *Proc. 35th IEEE Symposium on Foundations of Computer Science (FOCS)*, 09 2001.
- [4] Lydia E. Kavraki and Steven M. LaValle. *Motion Planning*. 2008.
- [5] Chaymaa Lamini, Said Benhlina, and Ali Elbekri. Genetic algorithm based approach for autonomous mobile robot path planning. 2018.